

Propuesta Proyecto: Recomendación de imágenes mediante entrenamiento multimodal

Alonso Casanova, Bruno Cerda, Berioska Maureen Contreras

May 8, 2026

1 Descripción del problema y justificación

Históricamente, los sistemas de recomendación se han entrenado únicamente sobre datos de interacciones entre usuarios e items (filtrado colaborativo), sin utilizar la información proporcionada por el contenido en sí (imágenes, videos, texto, etc.). Este enfoque puede presentar problemas, como por ejemplo el "arranque en frío", donde el modelo es incapaz de ofrecer buenas recomendaciones a usuarios nuevos.

Como una posible solución se estudian modelos entrenados de manera multimodal, i.e. sobre varios tipos de datos. La idea es que este nuevo modelo sea capaz de aprender la semántica y el contexto de los datos para ofrecer recomendaciones más completas y personalizadas. En este proyecto, nos enfocamos en el caso de recomendación de imágenes, y lo hacemos en base a modelos entrenados usando el historial de interacciones usuarios-items, las imágenes disponibles e información textual adicional de las imágenes (e.g. descripción, categoría, etc.). El dataset utilizado es Pixel-Rec[1], para esta entrega, se consideró un subconjunto de 50.000 datos de un total de 8 millones. Para disminuir el tamaño de los archivos y estandarizar las imágenes, estas se escalaron a 64×64 píxeles.

Mediante una revisión bibliográfica de métodos recientes, es posible identificar distintas arquitecturas que pueden ser consideradas como multimodales, sin embargo, todas se centran en lo siguiente: (1) Combinar las distintas modalidades mediante distintas redes neuronales específicas para cada modalidad (e.g. ResNet[5], BERT[6]) y, (2) utilizar redes neuronales que fueron entrenadas de manera nativa en múltiples modalidades (e.g CLIP[3]). En nuestro proyecto, vamos a replicar las arquitecturas EFMRec[4] y VL-CLIP[2], las cuales son sistemas recomendadores multimodales SOTA, y también vamos a introducir un nuevo modelo, el cual va a estar basado en estos dos (multimodal) pero con ciertas diferencias en su arquitectura.

2 Objetivos del proyecto

Al finalizar nuestro proyecto, esperamos poder cumplir con efectividad los siguientes objetivos:

1. Reconocer el estado del arte en modelos de recomendación multimodal.
2. Replicar dos modelos SOTA relacionados a sistemas recomendadores multimodales. Compararlos entre sí y con métodos de referencia elegidos como baseline (Random, Most-Popular y ALS).
3. Identificar mejoras en rendimiento al incluir entrenamiento multimodal frente a filtrado colaborativo clásico

3 Análisis descriptivo de los datos

Estudiamos primero la distribución de usuarios e imágenes, en la figura (1) vemos la distribución de cantidad de items visitados por cantidad de usuarios (en escala logarítmica) y la cantidad de interacciones registradas por fecha. En el primer gráfico vemos que la mayoría de los items tienen muy pocas interacciones, se observa una curva casi lineal en el gráfico, por otro lado, vemos que la gran mayoría de las interacciones se concentran en los años 2020-2022.




Figure 1: Dist. interacciones

Ahora vemos las características secundarias de las imágenes, número de visitas, comentarios, *likes* y compartidos. Se observa una curva muy similar al gráfico de la figura (1), la gran mayoría de las imágenes tiene muy pocas interacciones. Esto puede llevar a malos resultados en recomendación, pues es difícil relacionar imágenes con las que no se ha interactuado antes. Las distribuciones correspondientes se encuentran en la figura (2).




Figure 2: Dist. datos imágenes

El texto que acompaña a cada imagen involucra un título, tag y descripción. Nuestra idea preliminar es concatenar estos tres grupos de texto en un único cuerpo, para luego poder utilizar este vector de texto en métodos multimodales. Sobre la categoría asociada a cada imagen, vemos que también existe una gran diferencia en número de publicaciones, se registra una distribución parecida a la obtenida para la cantidad de vistas frente a la cantidad de ítems de la figura (2) por ejemplo. Las categorías más populares incluyen "Comedia", "Vida diaria", "Video-juegos" o "Películas", mientras que entre las menos populares están "Reptiles mascota" y "Tutoriales". La figura 3 contiene un ejemplo visual y textual de los datos de imagen y texto que el dataset contiene.

i192714.jpg



Title: My boyfriend gave me a turtle, and it suddenly grew hair these past two days.
Should I brush it off
Tag: Pet Reptiles
Description: Should I brush it off?

Figure 3: Ejemplo de imagen y el texto que tiene asociado en el dataset

En la tabla (1) se encuentran distintos valores de estadísticas descriptivas del dataset PixelRec50k que buscan resumir la información contenida en este subconjunto del dataset PixelRec. Tiene aproximadamente 1 millón de interacciones, exactamente 50.000 usuarios y más de 80.000 ítems. Notar que la densidad es bastante baja (0.02), por lo que hay mucha dispersión en los datos.

Table 1: Estadísticas del dataset pixelRec50K.

Estadística	
Número de usuarios	50,000
Número de ítems	82,865
Total de interacciones	989,494
Promedio de interacciones por usuario	19.79
Promedio de interacciones por ítem	11.94
Mayor número de interacciones por un usuario	434
Mayor número de interacciones por un ítem	146
Densidad (%)	0.0239

4 Implementación modelos de referencia

Los modelos baseline que elegimos fueron: (1) Random, (2) Most-Popular y (3) Alternating Least Squares (ALS). (1) y (2) fueron elegidos ya que permiten obtener valores en las métricas de un comportamiento no óptimo, en el sentido que (1) va a recomendar ítems sin ningún tipo de conocimiento previo, mientras que (2) va a recomendar según conocimiento previo general, por lo que no es específico para cada usuario. Finalmente (3) es nuestra baseline para cuantificar mediante las métricas un rendimiento aceptable que funciona solo mediante filtrado colaborativo, sin incorporar multimodalidad. En la tabla 1 se puede observar que ALS presenta un

mejor rendimiento que Most-Popular y Random, y de la misma manera Most-Popular es bastante mejor que Random.

Table 2: Comparación métricas MAP, nDCG y Recall para los modelos baseline.

Modelo	At-5 (@5)			At-10 (@10)		
	MAP	nDCG	Recall	MAP	nDCG	Recall
Random	0.00003	0.00005	0.00006	0.00003	0.00008	0.00016
Most Popular	0.00035	0.00050	0.00057	0.00035	0.00078	0.00133
ALS	0.00202	0.00296	0.00363	0.00194	0.00414	0.00674

5 Planificación para la etapa Midterm

- Mayo: Implementar los métodos SOTA que seleccionamos, en específico, EFMRec y VL-CLIP, estas dos arquitecturas nos va a permitir tener dos baselines competitivas en sistemas recomendadores multimodales, obteniendo valores base a superar con nuestro método en las métricas MAP, nDCG y Recall, @5 y @10.
- Junio: Implementación de un método nuevo. Se considerarán ajustes sobre los métodos SOTA, por ejemplo, una idea es reemplazar DINO[7] por YOLO[8] en VL-CLIP, con la teoría de que podemos mejorar el rendimiento mediante el reemplazo de Bounding Boxes por Segmentation Masks. Otras ideas son: Considerar la implementación del puntaje MCM (usado en problemas de detección de anomalías) o la distancia Mahalanobis para detectar imágenes cercanas entre sí. Una vez terminado lo anterior, comenzar la escritura del paper y del poster.
- Julio: Finalizar la escritura del paper y la del poster. Posterior a esto, incorporar el feedback de los ayudantes y actualizar el paper para obtener una versión final.

6 Bibliografía relevante

- [1] Y. Cheng, Y. Pan, J. Zhang, Y. Ni, A. Sun, and F. Yuan, “An Image Dataset for Benchmarking Recommender Systems with Raw Pixels”, *arXiv preprint arXiv:2309.06789*, 2023.
- [2] R. Giahhi, K. Yao, S. Kollipara, K. Zhao, V. Mirjalili, J. Xu, T. Biswas, E. Korpeoglu y K. Achan, “VL-CLIP: Enhancing Multimodal Recommendations via Visual Grounding and LLM-Augmented CLIP Embeddings,” *arXiv preprint arXiv:2507.17080*, 2025.
- [3] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever. “Learning Transferable Visual Models From Natural Language Supervision.” *arXiv preprint arXiv:2103.00020*, 2021.
- [4] L. Chen, P. Yi, X. Hou, C. Yang, and X. Cai. “When Modalities Go Missing: Early Fusion for Multimodal Recommendation.” In *Proceedings of the Nineteenth ACM International Conference on Web Search and Data Mining*, pp. 1094–1098. ACM, 2026.
- [5] K. He, X. Zhang, S. Ren, and J. Sun. “Deep Residual Learning for Image Recognition.” *arXiv preprint arXiv:1512.03385*, 2015.
- [6] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.” *arXiv preprint arXiv:1810.04805*, 2018.
- [7] M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, and A. Joulin. “Emerging Properties in Self-Supervised Vision Transformers.” *arXiv preprint arXiv:2104.14294*, 2021.
- [8] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi. “You Only Look Once: Unified, Real-Time Object Detection.” *arXiv preprint arXiv:1506.02640*, 2015.